

RAIJU CLOUD SYSTEM / RESEARCH

Libérer de l'espace disque sans perdre ses données

Rapport de recherche · RCS-RP-003 · Version 2.0

8 octobre 2026

Contributeur : Hugues Henrotte

DOI réservé : 10.5281/zenodo.23233639 — dépôt non publié

Terminal personnel Windows · Volume NTFS
Aucune donnée personnelle analysée

Résumé

Cette étude examine des façons sûres et mesurables de récupérer de l'espace sur un ordinateur Windows utilisé par une personne. Elle distingue la suppression de données, la désinstallation, le déplacement ou l'archivage, les fichiers cloud à la demande et la compression. L'expérience compare une archive ZIP PowerShell et la compression NTFS sur 26 fichiers de trois corpus publics — Canterbury, Canterbury Large et Silesia — et cinq cas synthétiques couvrant texte répétitif, JSONL structuré, binaire à forte entropie, archive déjà compressée et répertoire de petits fichiers. Les entrées sont épinglées et vérifiées; les corpus publics ne sont pas redistribués.

Le protocole comporte 110 exécutions de cas appariées, soit 220 mesures ZIP/NTFS, et les 26 sources publiques ainsi que les 220 transformations passent leurs contrôles d'intégrité. Sur les répertoires complets, les archives ZIP réduisent les octets logiques de 73,96 % (Canterbury), 70,80 % (Canterbury Large) et 67,81 % (Silesia). NTFS réduit l'allocation de 49,74 %, 37,46 % et 42,88 % respectivement. Ces corpus sont anciens et riches en contenus compressibles; ces valeurs ne prédisent pas l'espace récupérable dans une bibliothèque personnelle. Les résultats par échantillon, synthèses pondérées, répétitions et contrôles d'intégrité sont joints. La recommandation pratique est de mesurer, localiser les gros consommateurs avec un analyseur tel que WizTree, choisir l'action selon le risque et l'usage, puis vérifier l'espace libéré. Une treemap indique où l'espace est utilisé; elle ne détermine pas ce qui est inutile ou sûr à supprimer.

Mots-clés : stockage; Windows; NTFS; WizTree; compression; espace alloué; sauvegarde; hygiène numérique.

Abstract

This study examines safe and measurable ways to reclaim storage on a Windows personal computer. It distinguishes deletion, uninstalling software, moving or archiving files, cloud files-on-demand, and compression. The experiment compares PowerShell ZIP archives and Windows NTFS compression on 26 files from three public corpora (Canterbury, Canterbury Large, and Silesia) plus five synthetic cases representing repetitive text, structured text, high-entropy data, an already-compressed archive, and many small files. Inputs are pinned and checksum-verified; the public corpora are not redistributed.

Repeated trials distinguish logical file length from allocated space and verify SHA-256 integrity after reversible transformations. No personal file was inspected, and no pre-existing file was changed or deleted. The experiment answers only what these mechanisms did to these samples on one NTFS system; it cannot forecast savings on a reader's computer. The accompanying data package publishes per-sample results, weighted summaries, repeat variation, and integrity checks. Because savings depend on file contents, a favourable synthetic log is not a forecast for photos, videos, games, documents, or personal libraries. The practical recommendation is to measure first, locate large items with an analyser such as WizTree, choose a risk-appropriate action, and verify the result. A treemap can show where space is used; it cannot decide whether an item is unnecessary or safe to delete.

1. Problème et objectifs

Le manque d'espace déclenche parfois des gestes à risque : suppression au hasard, nettoyage automatique mal compris, déplacement sans sauvegarde, ou compression globale de contenus déjà compressés. Ces gestes ne répondent pas au même problème. Une archive ne libère l'espace local que si l'original est ensuite retiré après vérification; une compression en place peut réduire l'allocation tout en gardant un chemin accessible; le cloud à la demande échange de l'espace local contre une dépendance réseau; une suppression libère de la place au prix de la perte de la donnée.

RP-003 étudie la gestion du stockage d'un terminal humain, pas d'un serveur. L'objectif est de comparer des transformations de stockage en conditions contrôlées, documenter les outils intégrés et WizTree à partir de leurs éditeurs, puis proposer une démarche prudente et vérifiable.

Question de recherche

Pour un utilisateur de PC Windows, quelles stratégies peuvent réellement réduire l'occupation locale, dans quelles situations la compression est-elle pertinente, et quelles vérifications réduisent le risque de perdre des données utiles ?

Hypothèses

- H1 : les réductions varient avec la redondance et le format; un taux unique ne représente pas les types de fichiers.
- H2 : une archive générique peut ajouter un surcoût sur des données déjà compressées ou à forte entropie.
- H3 : NTFS Compression peut diminuer l'espace alloué tout en conservant le contenu logique, sans garantir un gain pour chaque format.
- H4 : répétitions, vérification d'intégrité et distinction taille logique/allouée sont nécessaires à l'interprétation.

2. Cadre conceptuel et mesures

Supprimer retire la donnée et peut affecter Corbeille, instantanés, synchronisation et sauvegardes. C'est une décision de conservation, pas une optimisation neutre. **Désinstaller** une application via le mécanisme prévu n'est pas équivalent à supprimer son dossier. **Déplacer** dans un autre dossier du même volume ne libère généralement pas d'espace; déplacer vers un autre volume peut en libérer après validation de la copie. **Archiver** crée une copie regroupée, et ne produit un gain local net que si l'archive est vérifiée et les originaux retirés volontairement. **Fichiers cloud à la demande** peuvent retirer le contenu local, mais son accès peut dépendre d'Internet; synchronisation et sauvegarde indépendante ne sont pas synonymes.

Compression en place conserve les chemins d'accès tout en modifiant l'allocation; coût CPU, latence, compatibilité et batterie ne sont pas mesurés ici. **Nettoyage ciblé** suit les catégories et réglages de Windows.

- **Taille logique** : longueur des fichiers en octets avant transformation.
- **Octets alloués** : espace attribué par le système de fichiers; clusters et compression expliquent l'écart avec la taille logique.
- **Taille ZIP** : longueur de l'archive, en-têtes et métadonnées inclus.
- **Variation** : $(\text{sortie} / \text{référence pertinente} - 1) \times 100$; négatif = réduction, positif = augmentation.
- **Ratio entrée/sortie** : référence / sortie; supérieur à 1 signifie que la sortie est plus petite. La référence est logique pour ZIP et allouée avant compression pour NTFS; ces mesures ne sont pas interchangeables.
- **Intégrité** : manifeste SHA-256 des chemins relatifs et contenus après extraction ZIP ou compression NTFS.

L'allocation mesurée fichier par fichier n'est pas une prévision exacte de la jauge « espace libre » de l'ensemble du volume : métadonnées, granularité, fragmentation et autres activités interviennent. L'étude rapporte des fichiers contrôlés, non l'espace libre total d'un ordinateur.

3. Données et provenance

Les 26 fichiers publics proviennent de Canterbury, Canterbury Large et Silesia. Canterbury couvre notamment texte, code, HTML, feuille de calcul, fax et exécutable. Canterbury Large ajoute trois échantillons de grande taille. Silesia élargit les formats à des archives logicielles, bases de données, texte, PDF, HTML/XML, exécutable et imagerie médicale non compressée. `corpus-manifest.csv` liste les catégories, tailles, empreintes, URL et commits. Chaque source est vérifiée avant essai par longueur, MD5 disponible chez le miroir et SHA-256 du manifeste.

Les pages universitaires sont les références descriptives. Le téléchargement direct de Canterbury depuis l'hôte officiel renvoyait HTTP 403; les octets sont récupérés depuis des miroirs GitHub publics fixés à des commits immuables, puis comparés aux longueurs officielles et sommes disponibles. Le miroir Silesia fournit les MD5, tous revérifiés. Ces miroirs ne sont pas présentés comme approuvés par les auteurs. Les fichiers sources ne sont pas redistribués dans le dépôt RCS; seules les empreintes, résultats et scripts le sont.

Les corpus sont historiques. Canterbury reflète des collections des années 1990 et ses ratios historiques sont indiqués comme mis à jour en 2001. Silesia est également un corpus de référence ancien. Ils ne représentent pas les bibliothèques actuelles de jeux, vidéos modernes, HEIC, caches d'applications récentes ou installations Windows actuelles. Les ratios Canterbury publiés sont cités uniquement pour illustrer une variation selon fichier et méthode; ils ne sont ni agrégés avec les observations 2026 ni présentés comme benchmark logiciel moderne.

Les cinq cas synthétiques, générés localement et de façon déterministe : (1) journal répétitif de 8 MiB; (2) JSON Lines de 65 536 événements; (3) binaire de 8 MiB produit par générateur pseudorandom déterministe fondé sur SHA-256; (4) ZIP de ce binaire; (5) dossier de 1 000 petits fichiers de 96 octets. Aucun contenu ne vient d'un utilisateur. Journal et JSONL isolent la redondance; le binaire et son ZIP représentent des cas peu compressibles ou déjà compressés.

4. Protocole

Environnement et sécurité

Essais du 8 octobre 2026 sur un poste Windows et un volume NTFS. Le modèle matériel, nom d'utilisateur, volume total, espace libre et données du compte ne sont pas publiés et ne servent pas à l'analyse. Aucun dossier personnel n'a été scanné; aucun outil installé, réglage système changé, nettoyage ou suppression de données existantes n'a été réalisé. Chaque transformation porte uniquement sur une copie d'essai dans un répertoire temporaire dédié.

Bras A — ZIP

PowerShell Compress-Archive -CompressionLevel Optimal crée une archive à partir d'une copie du fichier ou dossier. La taille de l'archive est mesurée en octets; l'extraction est vérifiée par manifeste SHA-256 et taille logique. Le temps enregistré est descriptif, non un comparatif de performance standardisé.

Bras B — NTFS

Une copie séparée reçoit compact.exe /c /q /s:<répertoire>. L'allocation est mesurée avant et après, par fichier, via l'API Windows GetCompressedFileSizeW. Le manifeste logique est comparé à l'original. Le runner s'arrête à la première différence d'empreinte ou erreur de source.

Répétitions et analyse

Chaque fichier public est mesuré trois fois sur une copie indépendante. Canterbury et Canterbury Large sont aussi mesurés comme répertoires agrégés, trois répétitions chacun; le répertoire Silesia est mesuré une fois du fait de son coût, tandis que ses 12 fichiers ont chacun trois répétitions. Les cinq cas synthétiques ont cinq répétitions. Les tailles doivent être déterministes; les répétitions vérifient la stabilité du protocole, pas l'incertitude d'un échantillon de personnes ou machines.

Les synthèses par fichier rapportent nombre de répétitions, moyenne, médiane, minimum, maximum et écart-type d'échantillon. Les résultats par catégorie sont pondérés par octets : somme des sorties / somme des références, et non moyenne simple des pourcentages de fichiers, afin qu'un petit échantillon ne pèse pas autant qu'un gros. Pour ZIP, référence = octets logiques; pour NTFS, référence = octets alloués avant compression. Le tableau par cas et répétitions brutes permet de contrôler ces calculs.

5. Résultats

Les tableaux ci-dessous sont calculés depuis results.csv. Le tableau de corpus agrégé est distinct des lignes de fichiers : les résultats agrégés ne sont pas additionnés une seconde fois au corpus. Le tableau synthétique représente les cinq motifs contrôlés. Les annexes et le classeur livrent toutes les répétitions et tous les fichiers. Ces taux décrivent les entrées testées sur cet appareil, pas une économie garantie.

Résumé global par corpus

Tableau 1 — Essais agrégés par corpus; référence propre à chaque méthode.

Jeu / échantillon	Méthode	Entrée logique (octets)	Référence (octets)	Sortie médiane (octets)	Variation médiane	Essais
Canterbury · Complete corpus folder	NTFS compact	2 810 784	2 810 784	1 412 745	-49.74%	3
Canterbury · Complete corpus folder	ZIP Optimal	2 810 784	2 810 784	731 938	-73.96%	3
Canterbury-Large · Complete corpus folder	NTFS compact	11 159 482	11 159 482	6 979 584	-37.46%	3
Canterbury-Large · Complete corpus folder	ZIP Optimal	11 159 482	11 159 482	3 259 131	-70.79%	3
Silesia · Complete corpus folder	NTFS compact	211 938 580	211 938 580	121 049 088	-42.88%	1
Silesia · Complete corpus folder	ZIP Optimal	211 938 580	211 938 580	68 221 469	-67.81%	1

Sur les répertoires entiers, Canterbury (2 810 784 octets logiques) produit une archive médiane de 731 938 octets (-73,96 %); l'allocation NTFS passe à 1 412 745 octets (-49,74 %). Canterbury Large (11 159 482 octets) atteint 3 259 131 octets en ZIP (-70,80 %) et 6 979 584 octets alloués par NTFS (-37,46 %). Silesia (211 938 580 octets) donne 68 221 469 octets ZIP (-67,81 %) et 121 049 088 octets alloués NTFS (-42,88 %). L'agrégat Silesia n'a qu'une répétition; ses fichiers individuels en ont trois.

Cas synthétiques

Tableau 2 — Cinq motifs générés de façon déterministe.

Jeu / échantillon	Méthode	Entrée logique (octets)	Référence (octets)	Sortie médiane (octets)	Variation médiane	Essais
already-compressed-zip	NTFS compact	8 391 324	8 391 324	8 391 324	+0.00%	5
already-compressed-zip	ZIP Optimal	8 391 324	8 391 324	8 394 034	+0.03%	5
deterministic-binary-8MiB	NTFS compact	8 388 608	8 388 608	8 388 608	+0.00%	5
deterministic-binary-8MiB	ZIP Optimal	8 388 608	8 388 608	8 391 324	+0.03%	5

Jeu / échantillon	Méthode	Entrée logique (octets)	Référence (octets)	Sortie médiane (octets)	Variation médiane	Essais
repetitive-log-8MiB	NTFS compact	8 388 608	8 388 608	1 048 576	-87.50%	5
repetitive-log-8MiB	ZIP Optimal	8 388 608	8 388 608	28 714	-99.66%	5
small-files-1000	NTFS compact	96 000	96 000	96 000	+0.00%	5
small-files-1000	ZIP Optimal	96 000	96 000	161 997	+68.75%	5
structured-jsonl	NTFS compact	8 388 608	8 388 608	1 048 576	-87.50%	5
structured-jsonl	ZIP Optimal	8 388 608	8 388 608	184 883	-97.80%	5

Sur les cas synthétiques (médiane de cinq essais), ZIP réduit le journal de 8 MiB à 28 714 octets (-99,66 %) et le JSONL à 184 883 octets (-97,80 %). NTFS ramène chacun à 1 048 576 octets alloués (-87,50 %). Le binaire à forte entropie de 8 MiB devient un ZIP de 8 391 324 octets (+0,03 %); sa propre archive, de 8 391 324 octets, devient un ZIP imbriqué de 8 394 034 octets (+0,03 %). NTFS ne réduit ni l'un ni l'autre. Pour 1 000 petits fichiers représentant 96 000 octets logiques, ZIP augmente l'archive à 161 997 octets (+68,75 %) et NTFS n'économise aucun octet alloué dans cette expérience. Le coût fixe de l'archive peut dépasser le contenu quand les fichiers sont très petits.

Corpus publics

Durées

Les durées end-to-end du CSV incluent création ZIP ou commande NTFS sans contrôle thermique ni isolation des activités d'arrière-plan. Elles ne sont pas un classement de vitesse. Aucune conclusion sur CPU, latence, énergie ou batterie n'en est tirée.

6. Discussion

Le comportement dépend du contenu, non du seul suffixe ou de la taille affichée. Le texte répétitif offre plus de redondance; un média ou une archive déjà compressée a souvent moins de motifs à éliminer et l'enveloppe ZIP peut augmenter la taille. Les corpus diversifient les entrées mais leur âge empêche de prédire le résultat de formats populaires actuels.

ZIP et NTFS répondent à des usages différents. ZIP crée une archive distincte, pratique au transport et rangement, mais requiert extraction pour l'usage normal. NTFS agit sur l'allocation tout en gardant les chemins accessibles. Aucun outil ne détermine quels fichiers sont inutiles. Une archive ne libère l'espace local que si l'archive est validée, sa sauvegarde prévue et les originaux retirés volontairement.

Taille logique et octets alloués répondent à deux questions. WizTree les expose et décrit des causes d'écart, dont compression, unités d'allocation et certaines métadonnées. Une treemap n'indique ni valeur du contenu, statut de sauvegarde ni dépendances d'application. L'élévation de privilèges élargit aussi l'inspection; commencer avec droits utilisateur et n'élever que pour un besoin précis réduit l'exposition.

Storage Sense agit suivant les catégories et paramètres. Le bon usage est de lire la configuration de Corbeille, Téléchargements et fichiers cloud avant confirmation et de mesurer après. L'automatisation n'est pas une recommandation universelle de suppression. Les fichiers cloud disponibles uniquement en ligne réduisent le stockage local mais peuvent nécessiter Internet; suppression et synchronisation peuvent se propager.

7. Procédure pratique

1. **Mesurer.** Dans Paramètres → Système → Stockage, noter espace libre, volume et catégories avant action.
2. **Localiser sans supprimer.** Utiliser WizTree ou équivalent provenant d'une source fiable. Commencer sans privilèges élevés; protéger tout export d'inventaire comme une donnée privée.
3. **Classifier.** Séparer applications, caches recréables, fichiers personnels, contenus de jeux, médias, archives, sauvegardes et dossiers synchronisés. Vérifier propriétaire et dépendances.
4. **Choisir l'action minimale.** Désinstaller via Windows; nettoyer les éléments identifiés; déplacer vers un autre volume; archiver; utiliser Files On-Demand si accès réseau acceptable; compresser une copie d'échantillon redondant.
5. **Sauvegarder et vérifier.** Vérifier l'ouverture d'une copie indépendante avant suppression; ne pas confondre synchronisation et sauvegarde.
6. **Une action à la fois.** Ne pas modifier à la main Windows, Program Files ou données d'application sur seule base de leur taille.

7. **Re-mesurer.** Confirmer espace libre, bon fonctionnement des applications, récupération des archives et possibilité de restauration.
8. **Prévenir la récursive.** Revoir téléchargements hors ligne, captures/vidéos, bibliothèques de jeux, destinations des nouveaux fichiers volumineux et rétention des sauvegardes.

WizTree : repérer, puis décider

WizTree est un analyseur de stockage, pas un nettoyeur automatique. Sa documentation distingue « Size » (taille logique) et « Allocated » (allocation) et explique que les totaux peuvent diverger de Windows. La fonction de balayage NTFS rapide requiert des privilèges élevés selon l'éditeur; ne les utiliser que si la vue correspondante est nécessaire et l'application digne de confiance. Une grande case dans la treemap est un indice d'enquête, jamais une autorisation de suppression : le fichier peut contenir sauvegardes, données de jeu, base de données ou contenu non régénérable.

Quand essayer la compression

Elle mérite un test sur copie quand les données sont redondantes, peu consultées, restaurables, et que le format d'archive est adapté. Ne pas viser tout un volume ou des données critiques d'emblée. JPEG, HEIC, MP4, audio compressé et archives ZIP/7z/RAR se prêtent généralement mal à une seconde compression importante. Les taux de cette étude ne remplacent pas un échantillon personnel choisi et testé avec consentement hors du périmètre de cette recherche.

8. Limites, validité et éthique

Validité externe. Un seul poste, NTFS, deux mécanismes et des corpus historiques limitent la généralisation. Aucun exFAT, ReFS, stockage cloud, format moderne AV1/HEIC, cache navigateur actuel, jeu récent ou snapshot n'est testé. Les essais ne constituent pas un échantillon aléatoire de PC de particuliers.

Validité interne. Les répétitions contrôlent protocole et tailles, pas la représentativité de la population. Les sources miroir constituent une limite malgré les commits épinglés et checksums. L'API mesure l'allocation des fichiers, non toutes les métadonnées, la fragmentation ou l'espace libre global. Les métadonnées ZIP, versions et activité du système peuvent affecter tailles ou durées marginalement. Les temps sont descriptifs.

Sources externes. Microsoft et WizTree décrivent leurs produits; il ne s'agit pas d'un essai indépendant d'efficacité ou de sécurité. La table de ratios historiques Canterbury date de 2001. Aucun produit de nettoyage, analyseur, service cloud ou outil 7-Zip n'a été comparé.

Protection des données. Aucun fichier ou volume personnel n'a été inspecté. Les essais utilisent exclusivement des contenus publics ou synthétiques et des copies créées dans le dossier dédié. Les empreintes publiées ne portent pas sur des fichiers privés. Les corpus bruts ne sont pas redistribués. Le runner supprime ses copies d'essai propres lorsqu'il le peut; aucun nettoyage ne cible des données de scratch préexistantes.

9. Conclusion

Récupérer de l'espace est un problème de décision et de conservation, pas seulement de compression. Mesurer et localiser précède la suppression; l'action dépend de l'usage, de la redondance, de la destination et de la sauvegarde. Les essais étendus apportent une comparaison reproductible sur plusieurs familles d'entrée, tout en explicitant les limites d'un poste et de corpus anciens. Ils ne donnent ni taux universel ni permission de suppression.

Pour une personne, la démarche défendable est d'observer avec Windows et un analyseur tel que WizTree, classifier, choisir une action minimale et réversible, sauvegarder, vérifier, puis mesurer de nouveau. La compression est un outil ciblé; elle ne remplace pas le jugement sur la valeur d'un fichier.

Annexe A — Résultats détaillés par fichier

Tableau A1 — Médianes par entrée publique et méthode (3 répétitions chacune).

Jeu / échantillon	Méthode	Entrée logique (octets)	Référence (octets)	Sortie médiane (octets)	Variation médiane	Essais
Canterbury · alice29.txt	NTFS compact	152 089	152 089	106 496	-29.98%	3
Canterbury · alice29.txt	ZIP Optimal	152 089	152 089	54 518	-64.15%	3
Canterbury · asyoulik.txt	NTFS compact	125 179	125 179	86 016	-31.29%	3
Canterbury · asyoulik.txt	ZIP Optimal	125 179	125 179	49 013	-60.85%	3
Canterbury · cp.html	NTFS compact	24 603	24 603	16 384	-33.41%	3
Canterbury · cp.html	ZIP Optimal	24 603	24 603	8 067	-67.21%	3
Canterbury · fields.c	NTFS compact	11 150	11 150	8 192	-26.53%	3
Canterbury · fields.c	ZIP Optimal	11 150	11 150	3 230	-71.03%	3
Canterbury · grammar.lsp	NTFS compact	3 721	3 721	3 721	+0.00%	3
Canterbury · grammar.lsp	ZIP Optimal	3 721	3 721	1 336	-64.10%	3
Canterbury · kennedy.xls	NTFS compact	1 029 744	1 029 744	385 024	-62.61%	3
Canterbury · kennedy.xls	ZIP Optimal	1 029 744	1 029 744	204 106	-80.18%	3
Canterbury · lcet10.txt	NTFS compact	426 754	426 754	290 816	-31.85%	3
Canterbury · lcet10.txt	ZIP Optimal	426 754	426 754	145 016	-66.02%	3
Canterbury · plrabn12.txt	NTFS compact	481 861	481 861	364 544	-24.35%	3
Canterbury · plrabn12.txt	ZIP Optimal	481 861	481 861	195 377	-59.45%	3
Canterbury · ptt5	NTFS compact	513 216	513 216	122 880	-76.06%	3
Canterbury · ptt5	ZIP Optimal	513 216	513 216	56 565	-88.98%	3
Canterbury · sum	NTFS compact	38 240	38 240	24 576	-35.73%	3
Canterbury · sum	ZIP Optimal	38 240	38 240	13 088	-65.77%	3
Canterbury · xargs.1	NTFS compact	4 227	4 227	4 096	-3.10%	3
Canterbury · xargs.1	ZIP Optimal	4 227	4 227	1 842	-56.42%	3
Canterbury-Large · E.coli	NTFS compact	4 638 690	4 638 690	2 899 968	-37.48%	3
Canterbury-Large · E.coli	ZIP Optimal	4 638 690	4 638 690	1 342 094	-71.07%	3
Canterbury-Large · bible.txt	NTFS compact	4 047 392	4 047 392	2 400 256	-40.70%	3
Canterbury-Large · bible.txt	ZIP Optimal	4 047 392	4 047 392	1 191 995	-70.55%	3
Canterbury-Large · world192.txt	NTFS compact	2 473 400	2 473 400	1 679 360	-32.10%	3
Canterbury-Large · world192.txt	ZIP Optimal	2 473 400	2 473 400	725 086	-70.68%	3
Silesia · dickens	NTFS compact	10 192 446	10 192 446	7 147 520	-29.87%	3
Silesia · dickens	ZIP Optimal	10 192 446	10 192 446	3 871 740	-62.01%	3
Silesia · mozilla	NTFS compact	51 220 480	51 220 480	28 700 672	-43.97%	3
Silesia · mozilla	ZIP Optimal	51 220 480	51 220 480	19 089 230	-62.73%	3
Silesia · mr	NTFS compact	9 970 564	9 970 564	5 951 488	-40.31%	3
Silesia · mr	ZIP Optimal	9 970 564	9 970 564	3 676 037	-63.13%	3
Silesia · nci	NTFS compact	33 553 445	33 553 445	10 440 704	-68.88%	3
Silesia · nci	ZIP Optimal	33 553 445	33 553 445	3 200 286	-90.46%	3
Silesia · ooffice	NTFS compact	6 152 192	6 152 192	4 542 464	-26.17%	3
Silesia · ooffice	ZIP Optimal	6 152 192	6 152 192	3 097 400	-49.65%	3
Silesia · osdb	NTFS compact	10 085 684	10 085 684	9 031 680	-10.45%	3
Silesia · osdb	ZIP Optimal	10 085 684	10 085 684	3 695 270	-63.36%	3
Silesia · reymont	NTFS compact	6 627 202	6 627 202	3 735 552	-43.63%	3
Silesia · reymont	ZIP Optimal	6 627 202	6 627 202	1 860 977	-71.92%	3
Silesia · samba	NTFS compact	21 606 400	21 606 400	10 424 320	-51.75%	3
Silesia · samba	ZIP Optimal	21 606 400	21 606 400	5 451 507	-74.77%	3

Jeu / échantillon	Méthode	Entrée logique (octets)	Référence (octets)	Sortie médiane (octets)	Variation médiane	Essais
Silesia · sao	NTFS compact	7 251 944	7 251 944	6 832 128	-5.79%	3
Silesia · sao	ZIP Optimal	7 251 944	7 251 944	5 331 897	-26.48%	3
Silesia · webster	NTFS compact	41 458 703	41 458 703	23 785 472	-42.63%	3
Silesia · webster	ZIP Optimal	41 458 703	41 458 703	12 214 053	-70.54%	3
Silesia · x-ray	NTFS compact	8 474 240	8 474 240	8 364 032	-1.30%	3
Silesia · x-ray	ZIP Optimal	8 474 240	8 474 240	6 045 219	-28.66%	3
Silesia · xml	NTFS compact	5 345 280	5 345 280	2 093 056	-60.84%	3
Silesia · xml	ZIP Optimal	5 345 280	5 345 280	688 095	-87.13%	3

La variation compare chaque sortie à la référence de sa méthode. Pour les répétitions brutes, écarts-types et empreintes, consulter le classeur et les CSV.

Annexe B — Artefacts et reproduction

- `corpus-manifest.csv` : catégories, octets, SHA-256, MD5, URL et commits pour les 26 entrées.
- `sources.csv` : registre des sources, date de consultation, rôle et limites probatoires.
- `reproduce.ps1` : validation, génération des cas synthétiques, répétitions ZIP/NTFS et checks SHA-256.
- `analyze_results.py` : statistiques descriptives, graphiques et classeur Excel depuis les résultats.
- `results.csv`, `source-checks.csv`, `experiment-metadata.json` : observations et métadonnées.
- `summary-by-case.csv`, graphiques et `RCS-RP-003-data.xlsx` : vues dérivées et données consultables.

Pour reproduire sur Windows/NTFS, préparer le corpus selon le manifeste ou laisser le runner le télécharger, puis lancer powershell -NoProfile -ExecutionPolicy Bypass -File .\reproduce.ps1 -InputRoot <corpus-root> -OutputDirectory <dossier-sortie> -ScratchRoot <dossier-temporaire-dédié>. Le bypass ne vaut que pour le processus de cette commande; ne désactivez pas une politique générale de sécurité. Pour analyser, utiliser Python 3 avec Pillow et openpyxl : python .\analyze_results.py --input-dir <dossier-sortie> --output-dir <dossier-sortie>. Les corpus téléchargés ne sont pas intégrés au paquet public.

Références

1. University of Canterbury. The Canterbury Corpus et Large Canterbury Corpus. [source en ligne](#) (consulté le 8 octobre 2026).
2. University of Canterbury. Canterbury historical compression ratios. [source en ligne](#) (page historique; mise à jour indiquée : 3 mai 2001).
3. Silesia Corpus maintainers. Silesia compression corpus. [source en ligne](#) (consulté le 8 octobre 2026).
4. Microsoft Support. Storage settings in Windows. [source en ligne](#)
5. Microsoft Support. Manage drive space with Storage Sense. [source en ligne](#)
6. Microsoft Support. Free up drive space in Windows. [source en ligne](#)
7. Microsoft Learn. compact command. [source en ligne](#)
8. Microsoft Learn. Compression attribute. [source en ligne](#)
9. Microsoft Support. Save disk space with OneDrive Files On-Demand for Windows. [source en ligne](#)
10. Microsoft Support. Delete files or folders in OneDrive. [source en ligne](#)
11. Antibody Software. WizTree FAQ. [source en ligne](#)
12. Antibody Software. WizTree Guide. [source en ligne](#)
13. 7-Zip. 7z format. [source en ligne](#) (context only; not tested).
14. Microsoft Learn. Compact OS, single-instancing, and image optimization. [source en ligne](#) (context only; not tested).

Figure A1 — Corpus Silesia

Médiane de trois essais par fichier; un ratio supérieur à 1 indique une sortie plus petite.

